

Recommender dokumentacija - VolunteerHub

1. Opis implementacije recommender sistema

VolunteerHub koristi content-based recommender implementiran u ASP.NET Core backendu preko ML.NET-a. Sistem poredi profil korisnika sa aktivnim događajima i vraća personalizovane preporuke za mobilnu aplikaciju.

Primarni model:

- Tehnologija: ML.NET
- Pipeline: ``FeaturizeText`` za korisnicke i event tekstualne attribute, ``Concatenate("Features")``, zatim ``SdcaLogisticRegression``
- Ulazni korisnicki signali: ``UserSkills``
- Ulazni event signali: kategorija, naslov, opis, zahtjevi, lokacija i organizacija
- Pozitivni primjeri: korisnik je registrovan na smjenu događaja
- Negativni primjeri: događaji na koje se korisnik nije registrovao
- Output: score/probability i tekstualno objasnjenje preporuke

Fallback logika:

- Ako model jos nije istreniran ili nema dovoljno podataka, ``RecommendationService`` koristi keyword-based scoring.
- Fallback i dalje koristi stvarne podatke iz baze: vjestine korisnika, kategorije, naslov/opis događaja, featured flag i isti grad.
- Ako korisnik nema vjestine, vraćaju se istaknuti/najnoviji aktivni događaji.

2. Putanja glavne logike recommender sistema

Glavni fajlovi:

- ``backend/src/VolunteerHub.Infrastructure/ML/RecommendationTrainingService.cs``
- ``backend/src/VolunteerHub.Infrastructure/ML/RecommendationModels.cs``
- ``backend/src/VolunteerHub.Infrastructure/Services/RecommendationService.cs``
- ``backend/src/VolunteerHub.API/Controllers/EventsController.cs``

Trening se registruje kroz dependency injection i pokrece se periodicki svakih 24 sata. Model se snima na putanju:

``AppContext.BaseDirectory/ml_model/recommendation.zip``

Endpoint za mobilnu aplikaciju:

``GET /api/events/recommended?top=5``

Endpoint cita korisnika iz JWT tokena, ne iz query parametra.

3. Putanja UI ekrana gdje se prikazuju preporuke

Mobilna aplikacija prikazuje preporuke u:

- ``mobile/volunteer_hub_mobile/lib/screens/home/home_screen.dart``
- ``mobile/volunteer_hub_mobile/lib/screens/events/events_tab.dart``
- ``mobile/volunteer_hub_mobile/lib/services/api_service.dart``

Kartice prikazuju događaj, score i ``reasonTags``, npr. "Odgovara tvojim vjestinama: Prva pomoc, IT vjestine".

4. Testni korisnici za evaluaciju

Preporuceni testni login:

- Mobile korisnik: ``mobile` / `test``
- Dodatni volonteri: ``tarik@test.ba``, ``amra@test.ba``, ``mirza@test.ba``, ``lejla@test.ba` / `test``

Za kvalitetan prikaz preporuka korisnik mora imati povezane vjestine u tabeli ``UserSkills``, a baza mora imati objavljene događaje i smjene. Seed podaci se kreiraju kroz ``DatabaseSeeder``.

5. Kako testirati

1. Pokrenuti ``docker compose up --build``.
2. Prijaviti se kao ``mobile` / `test``.
3. Pozvati ``GET /api/events/recommended?top=5`` sa JWT tokenom.
4. Provjeriti da response sadrzi:
 - ``event``
 - ``score``
 - ``reasonTags``
5. U mobilnoj aplikaciji otvoriti pocetnu ili Events ekran i provjeriti da se prikazuju preporucene kartice sa objasnjenjem.

6. Ogranicenja

- Ako nema najmanje 10 trening primjera, ML model se ne trenira i koristi se fallback scoring.
- Model je content-based i ne koristi collaborative filtering.
- Lokacijska blizina je implementirana kao bonus za isti grad, ne kao GPS udaljenost.

7. Zakljucak

Implementacija odgovara prijavljenom zahtjevu: koristi ML.NET, TF-IDF tekstualne attribute, logisticku regresiju, periodican trening i API response sa objasnjenjem preporuke.